

¿Qué es la visión por computadora?

Hacer que las máquinas vean

Disciplina que desarrolla métodos para adquirir, procesar, analizar y comprender datos visuales, y convertirlos en descripciones e interpretaciones útiles del mundo.



1

Bajo nivel



Mejora y transforma imágenes.

2

Medio nivel



Segmenta, describe y clasifica objetos.

3

Alto nivel



Reconoce escenas, reconstruye y razona.




Renacimiento reciente:

deep learning + grandes datos + hardware

Aplicaciones de la visión por computadora

Del laboratorio al mundo real

Hoy la visión por computadora percibe, detecta, clasifica e interpreta imágenes para asistir decisiones en múltiples industrias.



1

Vehículos autónomos

Detectan carriles, peatones, señales y otros vehículos.

2

Retail y e-commerce

Reconocen productos, recomiendan y gestionan inventario.

3

Control de calidad

Inspeccionan defectos y automatizan la verificación.

4

Imagen médica

Detectan anomalías, segmentan estructuras y apoyan diagnósticos.




Retos transversales: variabilidad de datos, precisión, tiempo real, privacidad y ética.



Transfer learning y fine-tuning

Reutilizar conocimiento visual

Aprovecha modelos preentrenados para acelerar el aprendizaje en nuevas tareas. Es ideal cuando hay pocos datos, menos tiempo y presupuesto limitado.



1

Transfer learning

Usa un modelo preentrenado casi tal cual.

2

Fine-tuning

Reentrena la cabeza y, si hace falta, capas altas.

3

Cuándo conviene

Pocos datos, menor costo y entrenamiento más rápido.

4

Límite

Solo ayuda si el conocimiento previo es útil para la nueva tarea.



Clave práctica: capas iniciales = rasgos genéricos; capas finales = rasgos específicos.



Detección de objetos y YOLO

Clasificar + localizar en tiempo real

La detección de objetos identifica qué hay en una imagen y dónde está. YOLO reformula la tarea como una sola predicción sobre toda la imagen.

1. Imagen de entrada




2. División en rejilla $S \times S$



$S \times S$ celdas

3. Una sola pasada (YOLO)



4. Postproceso (NMS)



La imagen se divide en $S \times S$ celdas.



Cada celda predice B cajas.



Se predice confianza y clase para cada caja.

1

La tarea

Combina clasificación y localización con cajas delimitadoras.

2

YOLO

Procesa la imagen completa en una sola pasada.

3

Salida

Cada celda predice cajas, confianza y clase.

4

Evaluación

IoU mide solapamiento y mAP resume precisión y recall.




Postproceso: NMS elimina detecciones duplicadas y conserva las más confiables.



Segmentación de imágenes

Comprender píxel por píxel

La segmentación divide la imagen en regiones significativas. En lugar de solo ubicar objetos, crea máscaras que describen con mayor detalle la escena.



Semántica

Asigna una clase a cada píxel.



Instancias

Separa cada objeto con una máscara única.



Panóptica

Une el qué y el cuál en cada píxel.



Aplicaciones

Agricultura, conducción autónoma y análisis médico.




Idea central: más detalle espacial que la detección basada en cajas.



Modelos visión-lenguaje

Cuando imagen y texto aprenden juntos

Los VLM integran visión y lenguaje para resolver tareas multimodales. Aprenden correspondencias entre imágenes y texto mediante representación, alineación y preentrenamiento a gran escala.



1 Entradas

Combinan imagen, texto y pares imagen-texto.



2 Aprendizaje

Usan objetivos contrastivos, generativos y de alineación.



3 Hito

CLIP popularizó el zero-shot a partir de correspondencias visión-lenguaje.



4 Tareas

Captioning, VQA, retrieval, clasificación y detección.




Desafíos: ruido entre modalidades, desbalance y relaciones complejas.

MediaPipe y Pose Landmarker

Visión en tiempo real en el dispositivo

MediaPipe ofrece bibliotecas, modelos y herramientas para integrar IA rápidamente en apps multiplataforma. Pose Landmarker detecta cuerpos y estima 33 landmarks 3D con gran eficiencia.



1

MediaPipe Tasks

APIs y bibliotecas multiplataforma para desplegar soluciones.

2

Ecosistema

Modelos listos, Model Maker y Studio para personalizar y evaluar.

3

Pose Landmarker

Detecta cuerpos y estima 33 puntos de referencia 3D.

4

Tiempo real

Funciona en IMAGE, VIDEO y LIVE_STREAM; puede generar máscaras.




Optimizado para aplicaciones edge, fitness, interacción y análisis corporal.



Ética y sesgos en IA

Rendimiento sin responsabilidad no alcanza

Los modelos no solo aprenden patrones útiles: también pueden amplificar sesgos, vulnerar privacidad y producir daños sociales. La ética debe atravesar datos, diseño, evaluación y despliegue.



1

Sesgo



Puede surgir de datos, etiquetado, supuestos y decisiones de diseño.

2

Daños



Discriminación, desinformación, invasión de privacidad y exclusión.

3

Principios



No daño, seguridad, privacidad, transparencia y explicabilidad.

4

Gobernanza



Accountability, supervisión humana, fairness y trazabilidad.




Marco guía: enfoque de derechos humanos, diversidad e inclusión, según UNESCO.



Redes convolucionales

De píxeles a rasgos aprendidos

Una CNN aprende automáticamente las representaciones útiles. Reemplaza las características diseñadas a mano por una cadena de capas que transforma la imagen hasta volver las clases más separables.



1

Señales



Procesa señales 1D y 2D, especialmente imágenes.

2

Feature learning



Aprende rasgos útiles sin diseñarlos a mano.

3

End-to-end



Optimiza toda la cadena desde la imagen hasta la clase.

4

Objetivo



Transformar la representación para separar mejor las clases.





Idea central: la última capa suele ser lineal; el poder está en las transformaciones previas.



Capas convolucionales

Convolución, pooling y estructura espacial

Las CNN combinan capas convolucionales, pooling y capas finales densas. La convolución usa filtros pequeños con pesos compartidos, reduce parámetros y conserva la organización espacial de la imagen.




Lectura rápida: la fuerza de una CNN viene de filtros locales, reutilización de pesos y jerarquías de rasgos.



ImageNet, AlexNet y el big picture

Datos, escala e impacto

El gran salto de las CNN vino de combinar arquitecturas profundas con grandes volúmenes de datos. ImageNet e ILSVRC impulsaron este cambio, y AlexNet mostró cómo una red podía mapear imágenes a scores de clase con enorme efectividad.



1 Datos

ImageNet fue clave para entrenar deep learning visual.



2 AlexNet

Popularizó CNN profundas a gran escala en 2012.



3 Métrica

Top-5: acierta si la clase correcta está entre las cinco primeras.



4 Generalización

La meta es rendir bien en nuevas imágenes, no solo memorizar.




Conclusión: las CNN pueden verse como funciones de imágenes a scores de clase; los datos y la escala cambiaron el campo.




Visión por computadora

Del píxel a la percepción inteligente

La visión por computadora es el campo que permite a las computadoras adquirir, procesar, analizar y entender imágenes o video para producir información útil, descripciones, decisiones o acciones. Automatiza parte de lo que hace el sistema visual humano, pero usando modelos computacionales, datos y aprendizaje.



¿Cómo actúan las redes neuronales?



¿Por qué importan?

- Aprenden rasgos automáticamente sin diseñarlos a mano.
- Escalan con datos y cómputo: más datos, mejores modelos.
- Unifican muchas tareas de visión en un mismo marco.
- Mejoran el desempeño en problemas visuales complejos.

¿Por qué sigue siendo ML e IA?

- Machine learning**
Aprende una función a partir de datos y ajusta parámetros para reducir error.
- IA**
Usa esa percepción para representar el mundo, tomar decisiones y apoyar acciones inteligentes.

1

Qué es



Extraer información útil de imágenes y video.

2

Cómo opera



Aprende representaciones desde píxeles hasta conceptos.

3

Por qué redes neuronales



Hacen feature learning, end-to-end y escalan.

4

Lugar en IA



Percepción automática dentro de sistemas inteligentes.



Cierre: la visión por computadora transforma señales visuales en representaciones, inferencias y acciones; por eso conecta percepción, aprendizaje e inteligencia artificial.





Modelos preentrenados de Hugging Face

ViT, CLIP y DETR en una mirada

Estos tres modelos muestran tres formas distintas de usar conocimiento visual preentrenado: clasificar una imagen completa, razonar con lenguaje natural y localizar múltiples objetos en una escena. Compararlos ayuda a entender tareas, salidas, fortalezas y límites en visión por computadora.



Comparación rápida	ViT	CLIP	DETR
Tarea principal	Clasificación	Zero-shot	Detección
Tipo de categorías	Fijas	Abiertas	Fijas
Localización espacial	No	No	Sí
Velocidad de inferencia	Alta	Alta	Moderada



Cierre: ViT, CLIP y DETR no compiten exactamente entre sí; resuelven problemas distintos dentro del mismo ecosistema de visión por computadora.